Hujjatlarni klasterlash

Asosiy tushunchalar, atamalar
va algoritmlarning mohiyati

Klaster

Vektor

TF-IDF

K-means

Klasterlash nima?

Klasterlash hujjatlarni o‘xshash xususiyatlariga ko‘ra guruhlarga ajratish jarayonidir.

Nazoratsiz o‘rganish

Oldindan tayyor guruh yorliqlarisiz ma’lumotdagi tuzilmani aniqlash.

Hujjat

Tahlil qilinadigan alohida matn.

Korpus

Tahlil uchun yig‘ilgan hujjatlar to‘plami.

Klaster

O‘xshash hujjatlardan hosil bo‘lgan guruh.

Matnni tayyorlash atamalari

Tokenizatsiya	Matnni qayta ishlash birliklariga, odatda so‘zlarga ajratish.
Normalizatsiya	Matn yozuvini yagona qoidalarga moslash.
Stop-so‘zlar	Mazkur vazifada kam axborot beradigan va olib tashlanishi mumkin bo‘lgan birliklar.
Lemmatizatsiya	So‘zlarni lug‘atdagi asosiy shakliga keltirish.

Ma’lumotni son bilan ifodalash

Vektorlashtirish

Hujjat xususiyatlarini tartibli sonlar qatori ko‘rinishida ifodalash.

Belgi

Hujjatni tavsiflovchi o‘lchanadigan xususiyat.

Vektor

Belgi qiymatlarining bir xil tartibdagi sonli ro‘yxati.

Sonli ifoda hujjatlar o‘xshashligini matematik hisoblash imkonini beradi.

TF-IDF nima?

Atamaning hujjatdagi ahamiyatini sonli vazn bilan ifodalash usuli.

TF

Term Frequency

Atamaning bitta hujjatda qanchalik ko‘p uchrashini bildiradi.

IDF

Inverse Document Frequency

Atama korpusdagi qancha hujjatda uchrashiga bog‘liq. Kam tarqalsa, IDF yuqoriroq.

TF-IDF = TF × IDF

Vazn atamaning hujjat uchun sonli ahamiyatini bildiradi.

Hujjatlar o‘xshashligi

Sonli vektorlar o‘xshashlik yoki masofa mezoni bilan taqqoslanadi.

Kosinus o‘xshashligi

Vektorlar yo‘nalishining qanchalik yaqinligini o‘lchaydi.

Qiymat yuqoriroq bo‘lsa, o‘xshashlik kuchliroq.

Evklid masofasi

Vektorlar orasidagi to‘g‘ri chiziqli masofani o‘lchaydi.

Qiymat kichikroq bo‘lsa, vektorlar yaqinroq.

Oddiy K-means Evklid masofasining kvadratiga asoslanadi.

K-means nima?

Vektorlarni oldindan belgilangan K ta klasterga ajratadigan guruhlash algoritmi.

K

Klasterlar soni.

Means

Inglizcha “o‘rtacha qiymatlar”.

Sentroid

Klaster vektorlarining o‘rtacha qiymati, ya’ni markazi.

Algoritm masalani yechish uchun aniq tartibdagi hisoblash qoidalaridir.

K-meansning ishlash tamoyili

Boshlash — Algoritm K ta boshlang‘ich markazni tanlaydi.

Biriktirish — Har bir vektorni eng yaqin markazga bog‘laydi.

Yangilash — Har bir klaster vektorlarining o‘rtachasini hisoblab, markazini yangilaydi.

Takrorlash — Biriktirish va yangilashni to‘xtash sharti bajarilguncha davom ettiradi.

Iteratsiya: hisoblash qadamlarining bir marta takrorlanishi.

Boshqa klasterlash algoritmlari

Ierarxik klasterlash

Ierarxiya guruhlarning pog‘onali tuzilishini bildiradi.

Birlashtiruvchi turida kichik guruhlar bosqichma-bosqich yirik guruhlarga birlashadi.

Dendrogramma bu birlashishlar daraxti.

DBSCAN

Density-Based Spatial Clustering of Applications with Noise

Zich joylashgan vektorlarni guruhlaydi. Guruhlar sonini oldindan belgilash talab etilmaydi.

Shovqin: tanlangan mezon bo‘yicha klasterga kirmagan nuqtalar.

TF-IDF va K-meansning vazifasi

TF-IDF

Matndagi atamalarga
vazn beradi va hujjatni
sonli ifodalashga xizmat qiladi.

K-means

Tayyor sonli vektorlar
orasidagi yaqinlikka qarab
klasterlar hosil qiladi.

Natija belgilarga, o‘xshashlik mezoniga va algoritm sozlamalariga bog‘liq.

Hosil bo‘lgan guruhlarning mazmunini talqin qilish alohida bosqichdir.