AXBOROTLARNI IZLASH
VA AJRATIB OLISH

Hujjatlarni klasterlash

Algoritmlarni amalda qo‘llash

9 ta xabar misolida K-means



9 ta xabar, bitta savol

Bu xabarlarni qanday guruhlaysiz?

9

Xabarlar aralash. Guruhlar hali belgilanmagan.

ID	Xabarning qisqa mazmuni
X2	Futbol jamoasi oxirida gol urdi.
X5	Kompyuter dasturi yangi kod bilan ishlaydi.
X8	Oshga guruch va sabzi solindi.
X6	Kompyuter dasturi kodi sinovdan o‘tdi.
X1	Futbol jamoasi ikkita gol urdi.
X9	Guruch va sabzidan osh pishirildi.
X4	Kompyuter dasturi uchun kod yozildi.
X7	Osh uchun guruch va sabzi tayyorlandi.
X3	Futbol jamoasi gol urishni mashq qildi.

Klasterlash tushunchasi

Klaster

o‘xshash hujjatlar guruhi

Guruhlash mezoni

Matnlardagi sonli belgilarning yaqinligi.

Natijaning foydasi

Mavzularni ko‘rish va tegishli hujjatlarni izlash.

Tayyor mavzu nomlari algoritmga oldindan berilmaydi.

Matnni tayyorlash

01 Asl xabar

Futbol: jamoa bugun ikkita gol urdi.

02 Bir xil yozuv

futbol jamoa bugun ikkita gol urdi

03 Ajratilgan so‘zlar

futbol jamoa ikkita gol urdi

Bu misolda “bugun” so‘zi mavzuni ajratishga yordam bermaydi.

So‘zlarni son bilan ifodalash

TF-IDF so‘zning hujjat uchun ajratuvchi ahamiyatini ifodalaydi.

Hujjat	futbol	kod	guruch
X1	0,40	0,00	0,00
X2	0,40	0,00	0,00
X4	0,00	0,45	0,00
X7	0,00	0,00	0,41

X1 va X2 “futbol” belgisi bo‘yicha o‘xshash.

Faqat 3 ta so‘z ustuni ko‘rsatilgan. Hisoblashda barcha so‘zlar qatnashadi.

K-means bilan guruhlash

K = 3

Uchta guruh izlaymiz.

K qiymatini bu misol uchun o‘zimiz belgiladik.

1. Boshlang‘ich markazlarni tanlash
2. Har bir hujjatni eng yaqin markazga biriktirish
3. Har bir guruh markazini qayta hisoblash
4. Natija barqarorlashguncha 2- va 3-qadamni takrorlash

Guruh markazi qanday topiladi?

Markaz har bir sonli belgining o‘rtacha qiymatini oladi.

Hujjat	“futbol” qiymati
X1	0,402
X2	0,402
X3	0,342

(0,402 + 0,402 + 0,342) / 3

≈ 0,382

Markazning “futbol” qiymati

Algoritm qolgan so‘zlar uchun ham shu hisobni bajaradi.

Natija: 9 ta xabar, 3 ta klaster

Guruhlarni o‘qib, ularga mavzu nomlarini beramiz.

01

Sport

X1, X2, X3

futbol
jamoa
gol

02

Texnologiya

X4, X5, X6

dastur
kompyuter
kod

03

Taom

X7, X8, X9

osh
guruch
sabzi

Guruh nomi hisoblashdan keyin tanlandi.

Yangi xabar qaysi guruhga tushadi?

X10

“Futbol: jamoa yangi gol bilan g‘alaba qozondi.”

Sport

Texnologiya

Taom

Javobingizni matndagi so‘zlar bilan asoslang.

Yangi xabar Sport guruhiga tushdi

Mavjud markazlargacha masofa

Guruh	Masofa
Sport	0,590
Texnologiya	1,305
Taom	1,309

Eng kichik masofa

Sport

Yangi xabar mavjud markazga biriktirildi.

Matnni tayyorlash. Sonli ifodalash. Guruhlash.

Sifat matnlarga, so‘zlarni ifodalashga va K tanloviga bog‘liq.